

令和 7 年度修士論文

**動物種および環境の多様性に頑健な  
行動認識のためのマルチモーダル表現空間の構築**

Construction of Multimodal Representation Space Robust to Diversity  
of Animal Species and Environments

北海道大学大学院 情報科学院  
情報科学専攻 情報理工学コース  
自律系工学研究室  
修士 2 年 菊地 真優

平成 8 年 2 月 4 日

# 第 1 章

## 概要

本研究では、動物種および撮影環境の多様性に頑健な動物行動認識を実現するため、マルチモーダル表現学習に基づく共有表現空間の構築手法を提案する。動物行動認識は、動物園における個体管理や福祉評価を支援する重要な技術である。しかし、従来手法の多くは膨大な行動ラベル付きデータを必要とし、学習データに含まれない未知の行動（異常行動など）や、異なる撮影環境への適用が困難であるという課題があった。

そこで本研究では、RGB 映像から得られる外観情報と、オプティカルフローに基づく運動情報を統合するマルチモーダル表現学習手法を設計した。各モダリティから抽出された特徴を Gated Fusion に基づく統合機構により適応的に統合することで、行動に対して判別的な表現空間を形成する。さらに、獲得される表現から動物種固有の外観バイアスを除去するため、種分類器を用いた敵対的学習を導入し、動物種に依存しない純粋な行動特徴の獲得を目指す。

提案手法の有効性を検証するため、大規模動物行動データセットを用いて学習を行い、未知環境で撮影された動物園のホッキョクグマおよびアジアゾウの映像に対して評価を行った。クラスタリング指標を用いた評価の結果、提案手法は単一モダリティに基づく手法と比較して、動物種や環境の変化に対して頑健であり、かつ学習時に未定義の行動に対しても有効な行動表現を獲得できることを示した。

本研究の成果は、アノテーションコストを抑制しつつ、多様な実環境へ適用可能な動物行動認識システムの実現に寄与するものである。

# 目次

|       |                         |    |
|-------|-------------------------|----|
| 第 1 章 | 概要                      | 1  |
| 第 2 章 | 序論                      | 5  |
| 2.1   | 研究背景                    | 5  |
| 2.2   | 研究目的                    | 6  |
| 2.3   | 本論文の構成                  | 7  |
| 第 3 章 | 関連研究                    | 8  |
| 3.1   | 動物行動認識                  | 8  |
| 3.1.1 | 動物行動認識データセット            | 9  |
| 3.2   | 実環境における動物行動解析の事例        | 9  |
| 3.3   | 表現学習と行動埋め込み             | 9  |
| 3.4   | マルチモーダル表現学習             | 10 |
| 3.5   | 敵対的学習による不変表現学習          | 10 |
| 第 4 章 | 提案手法                    | 12 |
| 4.1   | 手法の概要                   | 12 |
| 4.2   | 入力動画の前処理                | 13 |
| 4.3   | RGB 映像に基づく外観特徴抽出        | 14 |
| 4.4   | オプティカルフローに基づく運動特徴抽出     | 14 |
| 4.5   | Gated Fusion による適応的特徴統合 | 16 |
| 4.6   | 距離学習による行動表現の構築          | 16 |
| 4.6.1 | 行動分類損失                  | 17 |
| 4.7   | 敵対的学習による種情報の分離          | 18 |

|                                                               |           |
|---------------------------------------------------------------|-----------|
| 目次                                                            | 3         |
| 4.8 目的関数と最適化 . . . . .                                        | 19        |
| 4.8.1 ハイパーパラメータの最適化 . . . . .                                 | 19        |
| <b>第 5 章 実験設定</b>                                             | <b>20</b> |
| 5.1 データセット . . . . .                                          | 20        |
| 5.1.1 Animal Kingdom Dataset . . . . .                        | 20        |
| 5.1.2 ホッキョクグマ監視映像 . . . . .                                   | 21        |
| 5.1.3 アジアゾウ監視映像 . . . . .                                     | 22        |
| 5.2 実装詳細 . . . . .                                            | 24        |
| 5.2.1 学習パラメータ . . . . .                                       | 25        |
| 5.2.2 ハイパーパラメータの最適化 . . . . .                                 | 25        |
| 5.3 評価指標 . . . . .                                            | 25        |
| 5.3.1 Adjusted Rand Index (ARI) . . . . .                     | 26        |
| 5.3.2 Normalized Mutual Information (NMI) . . . . .           | 26        |
| 5.3.3 定性的評価 . . . . .                                         | 26        |
| 5.4 実験の構成 . . . . .                                           | 27        |
| 5.4.1 実験 1: ホッキョクグマ監視映像における行動分類 . . . . .                     | 27        |
| 5.4.2 実験 2: アジアゾウ監視映像への汎化検証 . . . . .                         | 27        |
| 5.4.3 実験 3: ソースドメイン内での行動分類 (Animal Kingdom Dataset) . . . . . | 27        |
| <b>第 6 章 実験結果</b>                                             | <b>28</b> |
| 6.1 実験 1: ターゲットドメインでの行動分類 . . . . .                           | 28        |
| 6.1.1 定量評価結果 . . . . .                                        | 28        |
| 6.1.2 定性評価結果 . . . . .                                        | 30        |
| 6.2 実験 2: アジアゾウ監視映像への汎化検証 . . . . .                           | 32        |
| 6.2.1 定量評価結果 . . . . .                                        | 32        |
| 6.2.2 t-SNE による可視化 . . . . .                                  | 32        |
| 6.2.3 ホッキョクグマとの比較分析 . . . . .                                 | 33        |
| 6.3 実験 3: ソースドメイン内での行動分類 . . . . .                            | 34        |
| 6.3.1 定量評価結果 . . . . .                                        | 35        |
| 6.3.2 t-SNE による可視化 . . . . .                                  | 35        |
| 6.3.3 種識別器の分類精度 . . . . .                                     | 37        |



|                                        |           |
|----------------------------------------|-----------|
| 目次                                     | 4         |
| 6.3.4 特徴空間におけるクラス間距離の分析 . . . . .      | 38        |
| 6.3.5 ゲーティングパラメータの分析 . . . . .         | 39        |
| <b>第 7 章 考察</b>                        | <b>42</b> |
| 7.1 マルチモーダル統合の有効性 . . . . .            | 42        |
| 7.1.1 外観特徴と運動特徴の相補性 . . . . .          | 42        |
| 7.1.2 Gated Fusion の適応的統合能力 . . . . .  | 43        |
| 7.2 種に依存しない表現の獲得 . . . . .             | 43        |
| 7.2.1 敵対的学習によるドメイン不変性 . . . . .        | 43        |
| 7.2.2 種不変性と行動識別性のトレードオフ . . . . .      | 44        |
| 7.3 動物園実環境への適用可能性 . . . . .            | 44        |
| 7.3.1 常同行動検出による動物福祉への貢献 . . . . .      | 44        |
| 7.3.2 ロバストな 24 時間連続モニタリングの実現 . . . . . | 45        |
| 7.3.3 異種動物への汎化と課題分析 . . . . .          | 45        |
| 7.4 限界と今後の課題 . . . . .                 | 46        |
| <b>第 8 章 結論</b>                        | <b>51</b> |
| 8.1 本研究のまとめ . . . . .                  | 51        |
| <b>参考文献</b>                            | <b>54</b> |

## 第 2 章

# 序論

### 2.1 研究背景

近年、動物行動の定量的な解析は、動物園における個体管理や行動モニタリング、さらには動物福祉の向上を目的として、ますます重要となっている [1]. 動物の行動は、個体の精神的・身体的状態を反映する重要な指標であり [2], 特に常同行動と呼ばれる反復的な異常行動は、不適切な飼育環境や慢性的なストレスに起因することが報告されている [3].

従来、動物行動の評価は飼育員や研究者による目視観察に基づいて行われてきた. しかし、長時間にわたる継続的な観察には多大な人手と時間を要し、観察者間の主観的なばらつきや、24 時間にわたる連続的なモニタリングが困難であるといった課題がある. このような背景から、映像データを用いたコンピュータビジョン技術による動物行動認識の自動化への需要が高まっている.

深層学習に基づく行動認識技術は、人間の行動認識において高い性能を達成しており [4], 動物行動認識への応用も進められている. しかし、これらの手法の多くは膨大な行動ラベル付きデータを必要とするため、新たな動物種や撮影環境へ適用する際には、再度大規模なアノテーション作業が必要となる. 加えて、動物の行動は発生頻度に大きな偏りがあり、発生頻度が極めて低い稀な行動については、事前に十分な学習データを収集すること自体が困難である. 特に動物園環境では、動物種ごとの外観差や行動様式の多様性に加え、照明条件や檻による遮蔽といった撮影環境の影響が大きく、特定の環境で学習されたモデルをそのまま他環境へ適用（ドメイン汎化）することが困難であるという問題がある.

このような課題に対し、特定のドメインに依存しない行動に関する本質的な特徴を抽出し、動物種や環境の変化に頑健な表現を獲得することが重要である. その有効なアプロー

チとして、映像から得られる外観情報に加え、オプティカルフローに基づく運動情報を併用する Two-Stream 型のマルチモーダル表現学習が注目されている [5]。静的な外観特徴と動的な運動特徴を統合することで、単一のモダリティでは捉えきれない複雑な行動パターンを表現可能になると期待される。

さらに、表現学習の過程において、行動認識に不要な属性情報を抑制する手法として、敵対的学習を用いた不変表現学習が提案されている。Domain-Adversarial Neural Networks (DANN) [6] に代表されるこれらの手法は、人物認識や物体認識の分野において、ドメイン間の差異を克服した特徴表現の獲得に成功しており、動物行動認識への応用も期待されている。しかし、マルチモーダル表現学習と敵対的学習を組み合わせ、動物種および環境の多様性を同時に克服することを目的とした研究は、未だ十分に検討されていない。

## 2.2 研究目的

本研究の目的は、動物種および撮影環境の多様性に頑健な動物行動認識を実現するため、マルチモーダル表現学習に基づく共有表現空間の構築手法を提案することである。具体的には、RGB 映像から得られる外観情報と、オプティカルフローに基づく運動情報を統合することで、行動に関する判別的な特徴表現を学習する。

本研究の核心的な提案として、獲得される表現から動物種固有のバイアスを排除することを目的とした、種分類器との敵対的学習を導入する。これにより、動物種の違いというドメインの壁を越え、未知の環境および行動に対しても高い汎化性能を持つ、汎用的な行動表現の獲得を目指す。

本研究の主な貢献は以下の通りである：

1. 外観特徴と運動特徴を統合したマルチモーダル表現学習により、行動の本質的な特徴を捉える手法を提案した。
2. 敵対的学習を用いて動物種に依存しない不変表現を獲得する枠組みを構築した。
3. 学習時に未使用の動物種（ホッキョクグマ、アジアゾウ）を対象としたゼロショット評価により、提案手法の汎化性能を実証した。

本研究では、大規模動物行動データセット Animal Kingdom Dataset [7] を用いて提案手法の学習を行い、学習時に使用されていない動物園監視映像を用いた評価実験により、実環境における適用可能性を検証する。

## 2.3 本論文の構成

本論文の構成を以下に示す．第 2 章では，動物行動認識およびマルチモーダル表現学習，ならびに敵対的学習に関する関連研究について述べる．第 3 章では，本研究で提案するマルチモーダル表現学習および敵対的学習に基づく手法の詳細を説明する．第 4 章では，実験に用いたデータセットや実装条件，評価指標について述べる．第 5 章では，提案手法の実験結果を示し，単一モダリティ手法との比較や分析を行う．第 6 章では，実験結果に基づく考察を行い，提案手法の有効性や限界について議論する．最後に，第 7 章では本研究のまとめと今後の課題について述べる．

## 第 3 章

# 関連研究

### 3.1 動物行動認識

動物行動認識は、映像データから動物の振る舞いを自動的に解析する技術であり、その応用範囲は基礎的な生態学研究から動物園における飼育管理まで多岐にわたる。動物の行動は、個体の精神的、身体的、および認知的な状態を色濃く反映することが知られており [2]、近年では特に、動物福祉を客観的に評価するための重要な指標として注目されている [1]。

中でも、常同行動と呼ばれる反復的な異常行動は、不適切な飼育環境や慢性的なストレスに起因して発現することが報告されており、動物の健康状態や福祉水準を評価する上で極めて重要な指標となる [3]。従来、これらの行動評価は専門家による長時間の目視観察や記録に依存してきた。しかし、人手による観察は多大な労力と時間を要するだけでなく、観察者間の主観的ばらつきや、24 時間にわたる連続的なモニタリングが困難であるといった課題を抱えている。そのため、低コストかつ継続的な運用が可能であり、定量的な行動データを自動的に取得できるシステムの開発が強く求められている。

こうした背景のもと、近年の深層学習技術の発展は、動物行動解析の分野に大きな変革をもたらした。Convolutional Neural Networks (CNN) や Vision Transformer (ViT) [8] の登場により、画像分類や物体検出の精度は飛躍的に向上し、特定のデータセットにおいては、人間と同等、あるいはそれ以上の認識性能が報告されている。また、DeepLabCut [9] に代表される姿勢推定技術の進展により、映像から動物の関節位置を高精度に推定し、微細な動作を定量的に解析することも可能となった。

### 3.1.1 動物行動認識データセット

動物行動認識の研究において、大規模かつ多様なデータセットの整備は重要な課題である。Animal Kingdom Dataset [7] は、850 種類以上の動物種と 140 種類以上の行動クラスを含む大規模な公開動画データセットであり、動物種や撮影環境の違いに依存しない汎用的な行動表現の学習に適している。

一方、MammalNet [10] は哺乳類に特化したデータセットであり、KABR [11] はケニアの野生動物をドローンで撮影したデータセットである。これらのデータセットは、それぞれ特定の動物群や撮影環境に焦点を当てているため、多様な動物種への汎化性能を評価するには限界がある。

## 3.2 実環境における動物行動解析の事例

動物園環境における代表的な解析事例として、Wang ら [12] は、監視カメラ映像を用いたホッキョクグマの常同行動検出手法を提案している。この研究では、時間平均画像を用いた背景差分により動体を検出し、その重心軌跡の周期性を解析することで、往復歩行などの常同行動を特定している。照明変化や天候の影響を受けやすい屋外環境において、ロバストな検出を実現した点は、実運用を想定した重要な成果である。

一方で、同手法は特定の動物種（ホッキョクグマ）および移動軌跡という限定的な特徴量に依存しており、移動を伴わない行動や、外観の異なる他種への適用には課題が残る。より多様な行動を種横断的に認識するためには、軌跡情報に加え、身体の動きや外観の変化を含む高次元な表現学習が必要である。

## 3.3 表現学習と行動埋め込み

行動認識におけるアノテーションコストを削減し、未知の行動に対応するためのアプローチとして、表現学習 (Representation Learning) および距離学習 (Metric Learning) が注目されている [13]。表現学習は、意味的に類似したサンプル（同じ行動）が特徴空間上で近接し、意味的に異なるサンプル（異なる行動）が分離されるような判別的な埋め込み空間 (Embedding Space) を構築することを目的とする。

FaceNet [14] によって広く知られるようになったトリプレット損失 (Triplet Loss) な

どの距離学習手法は、クラス分類層を持たないため、学習データに含まれないクラスや、サンプル数の少ない希少な行動に対しても、特徴空間上の距離に基づいてクラスタリングや異常検知が可能となる。動物行動認識の文脈においても、この埋め込みに基づくアプローチは、教師なしあるいは半教師ありの行動解析を実現するための重要な基盤となる。

### 3.4 マルチモーダル表現学習

映像から行動を認識する際、単一のモダリティのみを用いた手法では、行動の本質的な特徴を十分に捉えることが困難な場合がある。この課題に対し、複数のモダリティを統合するマルチモーダル表現学習が有効であることが示されている。

Simonyan と Zisserman [5] は、RGB 画像から抽出される外観特徴と、オプティカルフローから抽出される運動特徴をそれぞれ独立した CNN で処理し、最終的に統合する Two-Stream 型のアーキテクチャを提案した。この手法は、静的な外観情報と動的な運動情報を相補的に活用することで、単一ストリームの手法を大幅に上回る認識精度を達成した。

近年では、CLIP [15] に代表されるように、異なるモダリティ間で共有された表現空間を学習するアプローチが注目されている。このような共有表現空間により、モダリティ間の対応付けや、ゼロショット認識などの柔軟なタスクへの対応が可能となる。

### 3.5 敵対的学習による不変表現学習

高次元な特徴表現を学習する際、行動認識に不要な属性情報（動物種や背景など）が特徴量に強く残存すると、汎化性能を阻害する要因となる。この問題に対処する手法として、敵対的学習（Adversarial Learning）を用いたドメイン適応が提案されている。

Domain-Adversarial Neural Networks (DANN) [6] では、特徴抽出器の後段にタスク分類器とドメイン識別器を配置し、勾配反転層（Gradient Reversal Layer）を用いて学習を行う。ドメイン識別器がドメインを識別できないように特徴抽出器を更新することで、特徴空間からドメイン特有の情報を抑制し、タスクに本質的な情報のみを保持した不変表現の獲得が可能となる。

Tzeng ら [16] は、Adversarial Discriminative Domain Adaptation (ADDA) を提案し、ソースドメインで学習した特徴表現をターゲットドメインに適応させる手法を示した。人物行動認識などの分野では、これらの敵対的学習に基づく手法の有効性が広く示さ

れている。

しかし、動物行動認識において、動物種をドメインとして扱い、種に依存しない表現を獲得する試みは未だ十分に検討されていない。動物は種によって体型や運動機能が大きく異なるため、単純なドメイン適応では共通の特徴を見出すことが困難であるためである。本研究では、この研究ギャップに着目し、マルチモーダル表現学習と敵対的学習を組み合わせることで、動物種に不変な行動表現の獲得を目指す。



## 第 4 章

# 提案手法

### 4.1 手法の概要

本研究では，ラベル付けされたデータが乏しい環境下や，学習時に含まれない未知の動物種に対しても頑健に機能する，行動に基づく特徴表現空間を構築することを目的とする．提案手法は，RGB 映像から得られる外観情報と，オプティカルフローから得られる動作情報を適応的に統合するマルチモーダル学習フレームワークである．さらに，学習された特徴空間から動物種に依存するバイアスを除去するため，敵対的学習に基づく種情報分離モジュールを導入する．

提案手法の処理フローは以下の通りである：

1. **入力動画の前処理**：入力映像を Sliding Window により固定長クリップへ分割
2. **外観特徴抽出**：VideoMAE [17] を用いて RGB 映像から外観特徴を抽出
3. **運動特徴抽出**：RAFT [18] でオプティカルフローを推定し，X3D [19] で運動特徴を抽出
4. **適応的特徴統合**：Gated Fusion により外観・運動特徴を適応的に統合
5. **距離学習**：トリプレット損失 [14] により行動クラスごとのクラスタリングを促進
6. **敵対的学習**：DANN [6] に基づく敵対的学習により種依存情報を除去

システム全体のアーキテクチャを図 4.1 に示す．




図 4.1: 提案手法の全体アーキテクチャ．入力映像は RGB ストリームとオプティカルフローストリームに分岐し、それぞれ VideoMAE と X3D により特徴抽出される．抽出された特徴は Gated Fusion により適応的に統合され、トリプレット損失と敵対的損失の組み合わせにより最適化される．

## 4.2 入力動画の前処理

入力映像は、撮影時間やフレーム数が動画ごとに異なるため、可変長の時系列データとして扱われる．しかし、多くの深層学習ベースの映像認識モデルでは、固定長の入力を前提として設計されており、可変長の映像をそのまま処理することは困難である．そこで本研究では、入力映像を一定長のクリップ列へと分割するため、Sliding Window に基づく前処理を採用する．

具体的には、特徴抽出エンコーダの入力サイズに合わせて、映像を固定フレーム長  $T$  のクリップへと分割する．例えば、エンコーダが  $T = 16$  フレームを入力とする場合、フレーム 1-16, 2-17, 3-18 のように、1 フレームずつ重複させながらクリップを生成する．このようなオーバーラップを持つ分割により、映像中の局所的な動作の連続性を保持したまま特徴抽出を行うことが可能となる．

各クリップは独立にエンコーダへ入力され、クリップ単位の特徴ベクトルが得られる．その後、得られた複数の特徴ベクトルは、時間方向に沿って集約され、Adaptive Average Pooling により映像全体を表現する単一の特徴ベクトルへと変換される．この処理により、映像長に依存しない固定次元の埋め込み表現を安定して得ることができる．

Sliding Window を用いた特徴抽出は、フレームを等間隔にサンプリングする手法 (Uniform Sampling) と比較して、短時間に発生する動作変化や局所的な運動パターンをより詳細に捉えることが可能であり、特に動物の微細な行動変化の検出において有効である．




図 4.2: Sliding Window による入力映像の分割．入力映像を  $T = 16$  フレーム長のクリップへ 1 フレーム刻みで分割し，フレーム 1-16, 2-17, 3-18 のように重複を持つ複数のクリップを生成する．各クリップは独立に特徴抽出器へ入力され，最終的に Adaptive Average Pooling により単一の特徴ベクトルへ集約される．

### 4.3 RGB 映像に基づく外観特徴抽出

RGB ストリームは，映像フレーム列から動物の外観や姿勢，および周囲環境の文脈情報を捉えることを目的とする．本研究では，事前学習済みの VideoMAE [17] エンコーダを用いて，各クリップから高次元の外観特徴を抽出する．

VideoMAE は，Masked Autoencoder の枠組みを映像データに拡張したモデルであり，映像パッチの一部をマスクして再構成する自己教師あり学習により事前学習されている．この学習により，VideoMAE は映像内の時空間的な文脈を効果的に捉える能力を獲得している．本研究では，ImageNet で事前学習された VideoMAE エンコーダを使用し，その重みを凍結（Freeze）した状態で特徴抽出器として利用する．これにより，動物の姿勢や周囲環境の文脈情報を 768 次元の特徴ベクトル  $\mathbf{E}_{VideoMAE} \in \mathbb{R}^{768}$  として抽出する．

VideoMAE への入力は，前節で述べた Sliding Window により生成された固定長のクリップ列である．図 4.3 に，RGB 映像から VideoMAE に入力されるクリップ生成の例を示す．

### 4.4 オプティカルフローに基づく運動特徴抽出

オプティカルフローストリームは，映像中の動物の動作に起因する時間的变化を捉えることを目的とする．オプティカルフローは，連続する 2 フレーム間における各画素の移動



図 4.3: RGB 映像における連続フレーム列の例. 動物の外観や姿勢, および周囲環境の文脈情報を含む特徴を VideoMAE エンコーダを用いて抽出する. VideoMAE は時空間的な文脈を捉える能力に優れており, 静止画では判別困難な行動の識別に寄与する.




図 4.4: RAFT により推定されたオプティカルフローの可視化例. 隣接フレーム間の画素移動の方向と大きさを, それぞれ色相と明度で表現している. オプティカルフローは外観情報に依存せず運動を明示的に表現できるため, 異なる動物種間での行動の共通性を捉える上で有効である.

ベクトルを表現したものであり, 被写体の運動情報を明示的に符号化できる.

本研究では, 隣接フレーム間の画素移動量を推定するため, RAFT (Recurrent All-Pairs Field Transforms) [18] を用いる. RAFT は, 反復的な最適化により高精度なオプティカルフロー推定を実現する深層学習ベースの手法であり, 遮蔽や大きな動きを含む困難な場面においても頑健な推定が可能である.

推定されたオプティカルフローは, 連続するフロー画像列として表現され, これを X3D [19] エンコーダへ入力することで, 動作に基づく運動特徴を抽出する. X3D は, 効率的な時空間畳み込みを実現する 3 次元 CNN アーキテクチャであり, Kinetics-400 データセットで事前学習されたモデルを使用する. 本研究では, X3D の重みも凍結した状態で使用し, 2048 次元の特徴ベクトル  $\mathbf{E}_{X3D} \in \mathbb{R}^{2048}$  を抽出する.

オプティカルフローを用いる利点は, 被写体の色や模様といった外観情報に依存せず, 運動そのものを明示的に表現できる点にある. これにより, 外観差の大きい異なる動物種間においても共通性の高い運動特徴表現を得ることが可能となり, 種に依存しない汎化性能の向上に寄与する.

## 4.5 Gated Fusion による適応的特徴統合

外観情報と動作情報は互いに補完的な関係にあるが、行動の種類や状況によってそれぞれの重要度は大きく異なる。例えば、「走る」や「泳ぐ」といった動的な行動では運動特徴が支配的となる一方、「立つ」や「座る」といった静的な行動では外観特徴がより重要となる。そこで本研究では、両者を単純に連結 (Concatenation) するのではなく、Gated Fusion モジュールを用いて入力に応じた適応的な重み付けを行う。

まず、X3D からの特徴量  $\mathbf{E}_{X3D} \in \mathbb{R}^{2048}$  と VideoMAE からの特徴量  $\mathbf{E}_{VideoMAE} \in \mathbb{R}^{768}$  を、それぞれ線形層を用いて共通の  $d = 512$  次元空間へ射影する：

$$\mathbf{E}'_{X3D} = \mathbf{W}_{X3D} \mathbf{E}_{X3D} + \mathbf{b}_{X3D} \quad (4.1)$$

$$\mathbf{E}'_{VideoMAE} = \mathbf{W}_{VideoMAE} \mathbf{E}_{VideoMAE} + \mathbf{b}_{VideoMAE} \quad (4.2)$$

次に、以下の式によりゲーティングベクトル  $\alpha \in [0, 1]^{512}$  を算出する：

$$\alpha = \sigma(\mathbf{W}_g [\mathbf{E}'_{X3D}; \mathbf{E}'_{VideoMAE}] + \mathbf{b}_g) \quad (4.3)$$

ここで、 $[\cdot; \cdot]$  はベクトルの連結、 $\mathbf{W}_g \in \mathbb{R}^{512 \times 1024}$  および  $\mathbf{b}_g \in \mathbb{R}^{512}$  は学習可能なパラメータ、 $\sigma(\cdot)$  はシグモイド関数を表す。ゲーティングベクトル  $\alpha$  の各要素は、対応する次元において運動特徴と外観特徴のどちらを重視するかを制御する。

最終的な統合特徴量  $\mathbf{F} \in \mathbb{R}^{512}$  は、次式により計算される：

$$\mathbf{F} = \mathbf{E}'_{X3D} \odot \alpha + \mathbf{E}'_{VideoMAE} \odot (1 - \alpha) \quad (4.4)$$

ここで、 $\odot$  は要素ごとの積 (Hadamard 積) を示す。この機構により、モデルは行動の種類や環境条件に応じて、外見情報と動作情報の寄与度を柔軟に調整できる。単純な連結や固定重み付けによる統合と比較して、Gated Fusion は入力依存の適応的な統合を実現し、多様な行動パターンへの対応力を向上させる。

## 4.6 距離学習による行動表現の構築

本研究では、行動に基づく特徴表現空間を構築するために、分類学習ではなく距離学習 (Metric Learning) を採用する。分類学習は学習時に定義されたクラスのみを識別できるのに対し、距離学習はサンプル間の相対的な類似度構造を学習するため、学習時に存在し

なかったクラスに対しても特徴空間上の距離に基づいて識別や検索が可能となる．この特性は，アノテーションコストの削減や，未知の動物種・行動への汎化において重要な利点となる．

本研究では，同一行動に属する映像クリップ同士の類似度を高め，異なる行動に属するクリップ間の類似度を低下させるため，Multi-Similarity 損失 [20] を用いる．Multi-Similarity 損失は，サンプルペア間の複数の類似度関係を同時に考慮することで，より効果的な埋め込み空間の学習を実現する．

具体的には，アンカーサンプル  $x_i$  に対して，正例集合  $\mathcal{P}_i$ （同一行動クラスに属するサンプル）と負例集合  $\mathcal{N}_i$ （異なる行動クラスに属するサンプル）を定義し，以下の損失関数を最小化する：

$$L_{ms} = \frac{1}{N} \sum_{i=1}^N \left\{ \frac{1}{\alpha} \log \left[ 1 + \sum_{k \in \mathcal{P}_i} e^{-\alpha(S_{ik} - \lambda)} \right] + \frac{1}{\beta} \log \left[ 1 + \sum_{k \in \mathcal{N}_i} e^{\beta(S_{ik} - \lambda)} \right] \right\} \quad (4.5)$$

ここで， $S_{ik}$  はサンプル  $x_i$  と  $x_k$  の間のコサイン類似度， $\alpha$  と  $\beta$  は正例・負例のペアに対する重み付けを制御するスケーリングパラメータ， $\lambda$  はベースとなる類似度閾値である．コサイン類似度  $S_{ik}$  は次式で計算される：

$$S_{ik} = \frac{\mathbf{F}_i \cdot \mathbf{F}_k}{\|\mathbf{F}_i\|_2 \|\mathbf{F}_k\|_2} \quad (4.6)$$

Multi-Similarity 損失は，困難な正例（類似度が低い正例）と困難な負例（類似度が高い負例）に自動的により大きな重みを付与する特性を持つ．これにより，学習が進むにつれて識別が困難なサンプルペアに焦点が当たり，より判別力の高い特徴空間が構築される．

この損失により，同一行動のサンプルは特徴空間上で近接し，異なる行動のサンプルは離れるように学習が進み，行動ごとに明確なクラスタ構造を持つ埋め込み空間の形成が促進される．

#### 4.6.1 行動分類損失

Multi-Similarity 損失による距離学習に加えて，行動クラスの分類精度を直接的に最適化するため，行動分類器  $C_a$ （Action Classifier）と行動分類損失  $L_{action}$  を導入する．

行動分類器  $C_a$  は，統合特徴量  $\mathbf{F}$  を入力とし，行動クラスの確率分布を出力する．行動分類損失  $L_{action}$  は，以下の交差エントロピー誤差として定義される：

$$L_{action} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{a,i}^{(c)} \log C_a(\mathbf{F}_i)^{(c)} \quad (4.7)$$

ここで、 $N$  はバッチサイズ、 $C$  は行動クラスの数、 $y_{a,i}^{(c)}$  はサンプル  $i$  の行動ラベルの one-hot 表現における第  $c$  成分、 $\mathbf{F}_i$  は入力映像  $x_i$  に対する統合特徴量を表す。

Multi-Similarity 損失がサンプル間の相対的な類似度構造を学習するのに対し、行動分類損失は各行動クラスの識別境界を明示的に学習する。両損失の併用により、クラスタ内の密集性とクラス間の分離性の両方を効果的に最適化できる。

## 4.7 敵対的学習による種情報の分離

異なる動物種間での汎化性能を高めるためには、埋め込み空間から種に依存した情報を排除し、純粋な行動情報のみを保持する必要がある。例えば、「歩く」という行動は、犬であれ馬であれホッキョクグマであれ、本質的には類似した運動パターンを含むはずである。しかし、各種の外観的特徴（毛色、体型など）が特徴空間に残存すると、種ごとに異なるクラスタが形成され、種横断的な行動認識が困難となる。

そこで本研究では、Domain-Adversarial Neural Networks (DANN) [6] に基づく敵対的学習を導入する。DANN は、特徴抽出器がドメイン（本研究では動物種）に依存しない不変表現を学習するよう誘導する手法である。

具体的には、統合特徴量  $\mathbf{F}$  に対して種識別器  $D_s$  (Species Discriminator) を接続し、その前段に勾配反転層 (Gradient Reversal Layer: GRL) を配置する。GRL は順伝播時には恒等写像として機能するが、逆伝播時には勾配の符号を反転させ、さらにスケールリングパラメータ  $\lambda_{grl}$  を乗算する：

$$\text{GRL}_{\lambda}(\mathbf{x}) = \mathbf{x}, \quad \frac{\partial \text{GRL}_{\lambda}(\mathbf{x})}{\partial \mathbf{x}} = -\lambda_{grl} \mathbf{I} \quad (4.8)$$

このスケールリングパラメータ  $\lambda_{grl}$  は、敵対的学習の強度を制御する重要なハイパーパラメータである。 $\lambda_{grl}$  が大きいと種情報の抑制が強くなるが、大きすぎると行動識別能力が低下する可能性がある。

学習過程において、種識別器  $D_s$  は種ラベル  $y_s$  を正しく分類するよう学習する。一方、特徴抽出器および Gated Fusion 層は、GRL により反転された勾配を受け取ることで、種識別を困難にする特徴表現を生成するよう更新される。この敵対的な学習ダイナミクス

により、特徴空間から動物種に由来する情報が徐々に除去される。

敵対的損失  $L_{adv}$  は、以下の交差エントロピー誤差として定義される：

$$L_{adv} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{s,i}^{(k)} \log D_s(\text{GRL}(\mathbf{F}_i))^{(k)} \quad (4.9)$$

ここで、 $N$  はバッチサイズ、 $K$  は動物種のクラス数、 $y_{s,i}^{(k)}$  はサンプル  $i$  の種ラベルの one-hot 表現における第  $k$  成分、 $\mathbf{F}_i$  は入力映像  $x_i$  に対する統合特徴量を表す。

距離学習による行動判別性が維持されるため、種情報のみを抑制しつつ、行動識別能力を損なわない表現学習が可能となる。

## 4.8 目的関数と最適化

提案手法全体の目的関数  $L_{total}$  は、距離学習による損失  $L_{ms}$ 、行動分類損失  $L_{action}$ 、および敵対的損失  $L_{adv}$  の加重和として定義される：

$$L_{total} = L_{ms} + \lambda_{action} L_{action} + L_{adv} \quad (4.10)$$

敵対的損失  $L_{adv}$  は目的関数に直接加算されるが、その影響度は GRL のスケールパラメータ  $\lambda_{grl}$  によって制御される。 $\lambda_{grl}$  が大きいと種情報の抑制が強まるが、大きすぎると行動識別能力が低下する可能性があるため、適切な値の設定が重要である。

行動分類損失  $L_{action}$  は行動クラスの識別境界を直接的に学習する。敵対的損失  $L_{adv}$  は GRL を介して種に依存した情報を特徴空間から除去する。これらを適切な重み付けで併用することで、クラスタ内の密集性とクラス間の分離性、および種不変性を効果的に最適化できる。

### 4.8.1 ハイパーパラメータの最適化

Multi-Similarity 損失のパラメータ  $\alpha$ ,  $\beta$ 、行動分類損失の重み係数  $\lambda_{action}$ 、および GRL のスケールパラメータ  $\lambda_{grl}$  は、モデルの性能に大きく影響する重要なハイパーパラメータである。これらの値を手動で調整することは困難であるため、本研究ではベイズ最適化に基づくハイパーパラメータ自動最適化フレームワークである Optuna [21] を使用した。

具体的な探索空間および最適化の詳細は第 5 章で述べる。



## 第 5 章

# 実験設定

### 5.1 データセット

本研究では、提案手法の有効性と未知の環境への汎化性能を検証するために、学習用として大規模な野生動物データセット（ソースドメイン）、評価用として実際の動物園で撮影された監視映像データセット（ターゲットドメイン）の 2 種類を使用した。

#### 5.1.1 Animal Kingdom Dataset

Animal Kingdom Dataset [7] は、850 種類以上の動物種と 140 種類以上の行動クラスを含む、大規模な公開動画データセットである。すべての動画は 24 fps の一定フレームレートで記録されており、撮影視点や背景環境、照明条件などにおいて高い多様性を有している。

このような多様性により、Animal Kingdom Dataset は動物種や撮影環境の違いに依存しない汎用的な行動表現の学習に適している。一方で、既存の行動認識データセットである MammalNet [10] や KABR [11] は、種数および行動クラス数の両面において多様性が限定的である。例えば、KABR データセットは 3 種類の動物カテゴリに対して 7 種類の行動のみを含み、MammalNet も哺乳類に限定された 12 種類の行動クラスから構成されている。これらと比較すると、Animal Kingdom Dataset ははるかに広範な動物種および行動を網羅しており、ゼロショット分類や距離ベースの行動認識といった汎化性能を重視するタスクに特に適している。

本研究では、行動表現空間の学習に焦点を当てるため、Animal Kingdom Dataset の




図 5.1: 学習用データセット (Animal Kingdom Dataset) の例

うち哺乳類 (Mammals) に属する動画のみを使用し、さらに各行動クラスについて 100 本以上の動画サンプルを有するものに限定した。その上で、以下の条件に基づきデータのフィルタリングを行った。

- 各動画に単一の動物種のみが映っていること
- 各クリップが 16 フレーム以上で構成されていること
- 単一の行動ラベルのみが付与されている動画であること

図 5.1 に Animal Kingdom Dataset の例を示し、表 5.1 には、本研究で使用した行動クラスと対応するクリップ数を示す。

### 5.1.2 ホッキョクグマ監視映像

提案手法によって学習された行動表現空間の未知環境への汎化性能を評価するため、Animal Kingdom Dataset には含まれない実環境データとして、札幌市円山動物園のホッキョクグマ館で撮影された監視映像データセットを使用した。

本データは 2020 年 8 月 30 日に、屋外のホッキョクグマ展示場に設置された固定カメラによって撮影されたものである。動画の解像度は  $368 \times 640$  ピクセル、フレームレート

表 5.1: 学習に用いた Animal Kingdom Dataset の行動クラスとクリップ数

| Action        | Number of clips |
|---------------|-----------------|
| Attending     | 119             |
| Eating        | 212             |
| Jumping       | 89              |
| Keeping still | 117             |
| Running       | 225             |
| Sensing       | 184             |
| Walking       | 512             |

は 1 fps であり，撮影期間を通じて常に単一のホッキョクグマ個体のみが映っている。

行動ラベルは飼育員による観察記録に基づいて付与した。具体的には，個体が単一の行動を一貫して示している 30 秒間の動画区間を手動で抽出し，それぞれに行動ラベルを割り当てた。対象とした行動クラスは，「Keeping still」，「Sleeping」，「Swimming」，「Walking」に加え，ペーシングや旋回運動などの反復的な異常行動を指す「Stereotypic behavior（常同行動）」である。常同行動は動物福祉の観点から重要な指標であり，継続的な監視が求められる行動である。

本データセットは，屋外特有の照明変化に加え，詳細な動作の視認を困難にする低解像度および低フレームレート（1 fps）といった，実環境特有のノイズを含んでいる。そのため，本データは，提案手法が実環境下においても頑健かつ汎化的な行動表現を獲得できているかを評価するための，挑戦的かつ現実的なテスト環境を提供する。

図 5.2 にホッキョクグマ監視映像の例を示し，表 5.2 に各行動クラスに対応するクリップ数をまとめる。

### 5.1.3 アジアゾウ監視映像

提案手法の汎化性能をさらに多角的に検証するため，ホッキョクグマとは異なる動物種であるアジアゾウの監視映像も評価用データセットとして使用した。本データは，札幌市円山動物園のゾウ舎に設置された固定カメラによって撮影されたものである。

本データセットの特徴として，飼育施設内で暮らす 2 頭のアジアゾウが対象となっている点が挙げられる。各動画クリップには常に単一の個体のみが映っているものの，ク



図 5.2: 評価用データセット（ホッキョクグマ監視映像）の例

表 5.2: ホッキョクグマ動物園データセットの行動ラベルとクリップ数

| Action               | Number of clips |
|----------------------|-----------------|
| Keeping still        | 30              |
| Sleeping             | 87              |
| Stereotypic behavior | 80              |
| Swimming             | 55              |
| Walking              | 17              |

リップによってどちらの個体（個体 A または個体 B）が含まれるかは異なる．これにより，ホッキョクグマデータセット（完全な単一個体）とは異なり，同一クラス内でも個体差による変動が含まれる，より実用に近い評価環境を提供する．

動画の解像度は  $2331 \times 1748$  ピクセル，フレームレートは 5 fps である．行動ラベルは飼育員による観察記録に基づいて付与され，ホッキョクグマと同様に，単一の行動を一貫して示している区間を手動で抽出した．

表 5.3 に各行動クラスに対応するクリップ数をまとめる．



図 5.3: 評価用データセット（アジアゾウ監視映像）の例

表 5.3: アジアゾウ動物園データセットの行動ラベルとクリップ数

| Action        | Number of clips |
|---------------|-----------------|
| Eating        | 37              |
| Keeping still | 17              |
| Walking       | 15              |
| Swimming      | 12              |
| Sleeping      | 9               |

## 5.2 実装詳細

本節では，提案手法の実装に関する詳細を述べる．ネットワークアーキテクチャについては第3章で述べた通りであり，本節では学習環境および学習パラメータに焦点を当



てる.

### 5.2.1 学習パラメータ

本実験では、最適化アルゴリズムとして Adam を採用した. また, Metric Learning においてはバッチ内のサンプル多様性が学習効率に大きく寄与するため, バッチサイズは比較的大きな値である 256 に設定した.

### 5.2.2 ハイパーパラメータの最適化

本手法の学習において, 目的関数に含まれる Multi-Similarity 損失のパラメータ  $\alpha$ ,  $\beta$ , 行動分類損失の重み係数  $\lambda_{action}$ , および GRL のスケーリングパラメータ  $\lambda_{grl}$  は, モデルの性能に大きく影響する重要なハイパーパラメータである. これらの値を手動で調整することは困難であるため, 本実験ではベイズ最適化に基づくハイパーパラメータ自動最適化フレームワークである Optuna [21] を使用した.

具体的には, Animal Kingdom Dataset の検証用サブセットに対する ARI と NMI の和を最大化することを目的関数として設定し, 以下の探索空間において最適化を行った:

- Multi-Similarity 損失のスケーリングパラメータ  $\alpha$ : 探索範囲 [3.0, 6.0]
- Multi-Similarity 損失のスケーリングパラメータ  $\beta$ : 探索範囲 [50.0, 70.0]
- 行動分類損失の重み  $\lambda_{action}$ : 探索範囲 [1.0, 3.0]
- GRL のスケーリングパラメータ  $\lambda_{grl}$ : 探索範囲 [0.5, 1.0]
- 学習率:  $\{1.0 \times 10^{-4}, 2.0 \times 10^{-4}, 3.0 \times 10^{-4}\}$
- Weight Decay:  $\{1.0 \times 10^{-4}, 1.0 \times 10^{-3}, 1.0 \times 10^{-2}\}$
- Dropout 率:  $\{0.3, 0.5\}$

Optuna による Tree-structured Parzen Estimator (TPE) を用いた 50 回の試行の結果, 最も検証スコア (ARI + NMI) が高かった設定を最終的な評価実験に採用した.

## 5.3 評価指標

学習された埋め込み空間において, 行動クラスがどの程度適切に分離されているかを定量的に評価するため, 抽出された特徴ベクトルに対して, コサイン距離を用いた凝集型クラスタリング (Agglomerative Clustering) を適用し, 正解ラベルとの一致度を測定し

た。本研究では教師なし学習による行動表現の獲得を目的としているため、直接的な分類精度ではなく、クラスタリングの品質を評価する指標を採用した。

### 5.3.1 Adjusted Rand Index (ARI)

Adjusted Rand Index (ARI) は、2 つのクラスタリング結果間の類似度を測定する指標であり、偶然による一致を補正している点が特徴である。ARI は以下の式で定義される：

$$\text{ARI} = \frac{\text{RI} - \mathbb{E}[\text{RI}]}{\max(\text{RI}) - \mathbb{E}[\text{RI}]} \quad (5.1)$$

ここで、RI は Rand Index であり、全サンプルペアのうち正しく同一クラスまたは異なるクラスに割り当てられたペアの割合を示す。ARI は  $[-1, 1]$  の範囲をとり、1 は完全一致、0 はランダム割当相当、負の値はランダムより悪い結果を示す。

### 5.3.2 Normalized Mutual Information (NMI)

Normalized Mutual Information (NMI) は、クラスタリング結果と正解ラベル間の相互情報量を正規化した指標である。NMI は以下の式で定義される：

$$\text{NMI}(U, V) = \frac{2 \cdot I(U; V)}{H(U) + H(V)} \quad (5.2)$$

ここで、 $I(U; V)$  はクラス割当  $U$  と正解ラベル  $V$  の相互情報量、 $H(\cdot)$  はエントロピーを表す。NMI は  $[0, 1]$  の範囲をとり、クラスサイズが不均衡な場合でも安定した評価が可能であるため、本研究のようにクラス間でサンプル数に偏りがあるデータセットに適している。

### 5.3.3 定性的評価

定量的評価に加え、学習された特徴空間の構造を視覚的に分析するため、t-SNE (t-distributed Stochastic Neighbor Embedding) [22] を用いて特徴ベクトルを 2 次元空間に射影した。t-SNE のハイパーパラメータとしては perplexity=30、learning rate=200 を使用した。この可視化により、同一行動クラスに属するサンプルが空間上で凝集しているか、また異なる行動クラス間で明確な分離が達成されているかを確認した。

## 5.4 実験の構成

本研究では、提案手法の性能を多角的に検証するため、以下の 3 つの実験を行う。

### 5.4.1 実験 1: ホッキョクグマ監視映像における行動分類

提案手法の実環境への適応能力と、未知の環境および未知の行動クラスに対する汎化性能 (Out-of-domain) を検証する。学習済みモデルに対し、学習時に一度も提示されていない「ホッキョクグマ監視映像」を入力し、同様にクラスタリング精度を評価する。ソースドメインとは画質や環境が大きく異なるターゲットドメインにおいて、動物の行動（特に常同行動などの重要な動作）が正しく分離されているかを確認する。

### 5.4.2 実験 2: アジアゾウ監視映像への汎化検証

提案手法の汎化性能をさらに多角的に評価するため、ホッキョクグマとは異なる動物種であるアジアゾウの監視映像に対しても評価を行う。これにより、提案手法が特定の動物種に依存しない汎用的な行動認識能力を持つかを確認する。特に、2 頭のゾウが混在するデータセットであるため、複数個体環境における提案手法の限界についても検証する。

### 5.4.3 実験 3: ソースドメイン内での行動分類 (Animal Kingdom Dataset)

提案手法が、学習に使用したデータ分布内 (In-domain) において、未知の動画クリップを正しくクラスタリングできるかを検証する。本実験では、前述のデータ分割においてテスト用として確保された、Animal Kingdom Dataset 全体の 10% に相当する未学習データを用いて評価を行う。具体的には、これらのテストデータを入力とし、教師なしクラスタリングを行った際の ARI および NMI を算出する。これにより、多様な動物種を含む本データセットにおいて、基本的な行動の特徴表現が適切に獲得できているかを確認する。



## 第 6 章

# 実験結果

本章では，提案手法の有効性を検証するため，ソースドメインとターゲットドメインにおいて異なる観点から評価を行う．ソースドメインでは，マルチモーダル表現学習および距離学習が設計通りに機能しているかを確認するため，特徴空間における幾何学的な構造（クラス内・クラス間距離）を重点的に分析する．一方，ターゲットドメインでは，未知の環境および行動に対する実用性を検証するため，最終的な行動識別精度（ARI, NMI）および t-SNE による可視化結果を用いて評価する．

本章では，提案手法の有効性を検証するために実施した 3 つの実験の結果を報告する．

### 6.1 実験 1: ターゲットドメインでの行動分類

本節では，学習時に一度も提示されていないホッキョクグマ監視映像に対する提案手法の汎化性能を評価する．これは，提案手法が未知の環境・行動クラスに対しても有効に機能するかを検証する最も重要な実験である．

#### 6.1.1 定量評価結果

札幌市円山動物園のホッキョクグマデータセットに対するクラスタリング性能を表 6.1 に示す．比較対象として，以下の 4 つの条件を設定した：

- **RGB Only**：VideoMAE による外観特徴のみを使用
- **Flow Only**：X3D によるオプティカルフロー特徴のみを使用
- **Gated Fusion (w/o Adv)**：提案する Gated Fusion を適用するが，敵対的学

表 6.1: ホッキョクグマ監視映像に対する各手法のクラスタリング性能比較

| 手法                     | ARI          | NMI          |
|------------------------|--------------|--------------|
| RGB Only               | 0.093        | 0.278        |
| Flow Only              | 0.557        | 0.539        |
| Gated Fusion (w/o Adv) | 0.615        | 0.622        |
| <b>Proposed (Full)</b> | <b>0.742</b> | <b>0.728</b> |

習は行わない

- **Proposed (Full)** : Gated Fusion と敵対的学習の両方を適用（提案手法）

表 6.1 より，以下の知見が得られた：

■**外観特徴のドメイン依存性** RGB 特徴のみを用いた場合，ARI は 0.093 と極めて低い結果となった．この著しい性能低下は，学習データ（ドキュメンタリー映像）と評価データ（監視カメラ映像）の間で生じる背景環境や照明条件といったドメインシフトの影響によるものと推察される．VideoMAE は優れた時空間表現能力を有するが，ドメイン間の乖離が大きい場合，行動固有の特徴よりも背景情報に過剰適合する傾向が見られ，単独での汎化には限界があることが示唆された．

■**運動特徴のドメイン不変性** 一方，オプティカルフロー特徴のみを用いた場合，ARI は 0.557 まで大幅に改善した．オプティカルフローは動物のテクスチャや背景情報の影響を受けにくく，純粋な動作情報を抽出できるため，ドメイン変化に対して高い頑健性を示したと考えられる．この結果は，未知環境への汎化において，運動情報がドメイン不変な重要な手がかりとなることを裏付けている．

■**適応的特徴統合の有効性** Gated Fusion を用いて両モダリティを統合したモデルは，ARI 0.615 を達成した．これは，運動特徴の頑健性を維持しつつ，外観特徴に含まれる文脈情報を適応的に補完することで，単一モダリティでは識別困難な複雑な行動パターンに対しても表現力が向上したためと解釈できる．

■**敵対的学習による種不変表現の獲得** 最終的な提案手法（Full）は ARI 0.742，NMI 0.728 と，比較手法の中で最も高い性能を記録した．単純な特徴統合（Gated Fusion）と比較して ARI が 0.127 ポイント向上した点は，敵対的学習が種に特有の情報を効果的に




図 6.1: ホッキョクグマデータセットにおける各手法の t-SNE 可視化結果. (a) RGB Only, (b) Flow Only, (c) Gated Fusion (w/o Adv), (d) Proposed (Full). 提案手法では各行動クラスが明確に分離されたクラスタを形成している.

抑制し、純粋な行動表現の獲得に成功していることを強く示唆している.

### 6.1.2 定性評価結果

#### t-SNE による特徴空間の可視化

学習された特徴空間の構造を視覚的に分析するため、各手法による埋め込みを t-SNE により 2 次元に射影した結果を図 6.1 に示す. なお、t-SNE は高次元の特徴空間を低次元に射影して可視化する定性的な手法であり、射影時のパラメータ設定によって見え方が変化する性質を持つ. したがって、本研究では t-SNE の結果はあくまで特徴空間の構造を直感的に理解するための補助的なものと位置づけ、モデルの定量的な性能評価は ARI および NMI に基づいて行う.

RGB Only では各行動クラスのサンプルが混在しており、明確なクラスタ構造が形成されていない. 一方、提案手法 (Full) では「Swimming」「Walking」「Sleeping」などの各行動クラスが明確に分離されたクラスタを形成しており、クラス間の境界も明瞭である.

特に注目すべき点として、動物福祉の観点で重要な「Stereotypic behavior (常同行動)」のクラスタが、「Walking」と若干混ざりながらも区別されている. これは、常同行動が歩行の一種でありながらも、その反復的なパターンが特徴空間上で識別可能であることを示唆しており、異常行動の自動検知への応用可能性を示している.

#### 行動クラス間の誤分類分析

混同行列および誤分類サンプルの詳細な分析から、以下の 2 つの主要な課題が明らかになった.

■**歩行 (Walking) と常同行動 (Stereotypic behavior) の境界** 一部の「Walking」が「Stereotypic behavior」のクラスタに誤って分類される事例が確認された。詳細な分析の結果、誤分類された「Walking」クリップの多くには、30 秒間の映像内で「折り返し動作」や「往復するような軌跡」が含まれていた。

本モデルはソースドメイン (Animal Kingdom Dataset) のみで学習されており、「常同行動」という概念を明示的には学習していない。しかし、結果として特徴空間上では、「特定位置での往復歩行」という物理的特徴に基づいたクラスタ (常同行動のグループ) が形成されている。誤分類された通常の「Walking」は、偶然にも常同行動と酷似した位置および軌跡を持っていたため、特徴空間上の距離計算において、通常の歩行クラスタよりもこの常同行動クラスタに近接してしまったと解釈できる。

■**低運動強度および環境ノイズによる混同** 「Walking」や「Swimming」、および「Keeping still」の間で相互に混同が見られた。詳細な映像確認の結果、この要因は以下の 2 点に集約される。第一に、断続的な動作の影響である。「Walking」中に数秒間立ち止まる動作が含まれる場合、オプティカルフローの強度が著しく低下し、モデルがこれを「静止 (Keeping still)」や「低運動な Swimming」と誤認する事例が散見された。第二に、視認性の悪さと環境ノイズの影響である。本データセットは低解像度かつ低フレームレートであるため、微細な遊泳動作 (Swimming) の視認が困難であり、モデルが動物の動きではなく「水面の揺らぎ」を誤って学習している可能性がある。その結果、水面が穏やかな Swimming や、逆に背景に動きがある Keeping still といった誤分類が生じたと考えられる。

**今後の展望：** 以上の誤分類分析から、さらなる精度向上には以下の 2 つの指針が重要であると結論付けられる。第一に、常同行動特有の「執拗な繰り返し」を捉えるための長期的文脈の導入である。30 秒程度のクリップでは単発の往復と常同的な反復の区別が困難であるため、数分単位的时间幅での頻度解析を行うことが有効であると考えられる。第二に、環境ノイズや断続的な静止に頑健な特徴抽出を行うための空間的アテンションの活用である。水面の揺らぎを抑制し、動物領域のみに焦点を当てることで、低解像度映像や低運動時においても安定した行動認識が期待される。

表 6.2: アジアゾウ監視映像に対する各手法のクラスタリング性能比較

| 手法                     | ARI          | NMI          |
|------------------------|--------------|--------------|
| RGB Only               | 0.212        | 0.423        |
| Flow Only              | 0.214        | 0.437        |
| Gated Fusion (w/o Adv) | 0.223        | 0.445        |
| <b>Proposed (Full)</b> | <b>0.249</b> | <b>0.473</b> |

## 6.2 実験 2: アジアゾウ監視映像への汎化検証

本節では，提案手法の汎化性能をさらに検証するため，ホッキョクグマとは異なる動物種であるアジアゾウの監視映像に対する評価を行う．これにより，提案手法が特定の動物種に依存しない汎用的な行動認識能力を持つかを確認する．

### 6.2.1 定量評価結果

アジアゾウ監視映像に対するクラスタリング性能を表 6.2 に示す．

表 6.2 より，アジアゾウデータセットにおいても提案手法 (Proposed Full) が，ARI および NMI の両指標において比較手法の中で最も高い性能を達成したことが確認された．ただし，ホッキョクグマデータセット (ARI: 0.742) と比較すると，性能が低下している．

### 6.2.2 t-SNE による可視化

アジアゾウデータセットにおける各手法の特徴空間を t-SNE により可視化した結果を図 6.2 に示す．

図 6.2 から，各行動クラスの分離性について以下の傾向が読み取れる．

まず，「Sleeping (黄)」は右上方に極めて凝集度の高い独立したクラスタを形成しており，他の行動と明確に分離されている．同様に，「Swimming (青)」も右下方に比較的まとまったクラスタを形成しているが，その近傍には「Keeping still (赤)」のサンプルの一部が近接しており，前節で述べた「低運動による混同」が特徴空間上の距離としても表れている．

一方で，左側に分布する「Walking (橙)」と「Eating (緑)」に注目すると，これらは




図 6.2: アジアゾウデータセットにおける各手法の t-SNE 可視化結果. ホッキョクグマと比較してクラスタの分離が不明瞭である.

単一の密なクラスタを形成せず、広範囲に分散している. さらに、両クラスの分布領域は大きく重複しており、明確な境界線が存在しない. また、「Keeping still (赤)」が単一の塊にならず、複数の箇所に分散している点は、背景や文脈によって異なる特徴表現が学習されていることを示唆している.

### 6.2.3 ホッキョクグマとの比較分析

表 6.3 に、ホッキョクグマとアジアゾウの両データセットにおける提案手法の性能比較を示す.

■**性能低下の要因分析** 性能低下の主な要因として、本データセットにおける「行動クラス定義の曖昧さ」および「クラス内分散の大きさ」が挙げられる.

表 6.3: ホッキョクグマとアジアゾウにおける提案手法の性能比較

| データセット  | ARI   | NMI   |
|---------|-------|-------|
| ホッキョクグマ | 0.742 | 0.728 |
| アジアゾウ   | 0.249 | 0.473 |

ホッキョクグマと比較して、アジアゾウの行動はクラス内のバリエーションが著しく大きい。具体的には、「Walking」クラスの中に、「一定速度での歩行」だけでなく、「停止を含む緩慢な歩行」や「鼻を高く上げながらの歩行」など、運動強度の異なる多様なサブパターンが混在している。その一方で、「Eating」クラスにおいても「歩きながら鼻を上げて餌を口に運ぶ」動作が含まれるなど、異なる行動クラス間で視覚的・運動的な類似性が高い動作が存在する。

加えて、「Keeping still」クラスにおける「背景コンテキストへの依存性」も無視できない要因である。t-SNE 上で本クラスが単一の塊にならず、Swimming や Eating の近傍など複数の箇所に分散している点は、同じ「静止」というラベルが付与されていても、その背景（水中か陸上か）や文脈によって、モデルが全く異なる特徴表現を学習してしまっていることを示唆している。

これらの「動作の多様性」と「背景の多様性」が、特徴空間におけるサンプルの凝集を妨げている。実際、t-SNE の可視化結果（図 6.2）で見られた広範な分布の重複や拡散は、単純なクラス定義では捉えきれないデータの複雑性がそのまま投影された結果であり、これが他クラスとの境界領域を増大させ、クラスタリング精度（ARI）の低下を招いたと結論付けられる。

### 6.3 実験 3: ソースドメイン内での行動分類

本節では、学習に使用した Animal Kingdom Dataset のテストセットに対する提案手法の性能を評価する。これにより、提案手法がソースドメイン内において基本的な行動認識能力を維持しているかを確認する。

表 6.4: Animal Kingdom Dataset のテストセットに対する各手法のクラスタリング性能比較

| 手法                     | ARI          | NMI          |
|------------------------|--------------|--------------|
| RGB Only               | 0.160        | 0.239        |
| Flow Only              | 0.205        | 0.266        |
| Gated Fusion (w/o Adv) | 0.238        | 0.285        |
| <b>Proposed (Full)</b> | <b>0.313</b> | <b>0.345</b> |

### 6.3.1 定量評価結果

Animal Kingdom Dataset のテストセットに対するクラスタリング性能を表 6.4 に示す.

ソースドメイン内での評価においても, 提案手法が最も高い性能を示した. 特筆すべき点は, 敵対的学習を導入した Proposed (Full) が, Gated Fusion (w/o Adv) と比較して ARI で約 0.075 ポイントの大幅な向上を達成したことである. 通常, ドメイン不変性を学習することは, ソースドメインに対する特化性能を犠牲にする可能性があるが, 本実験では逆に性能が向上する結果となった.

これは, Animal Kingdom Dataset 自体が多様な動物種を含んでいるため, 敵対的学習により種に依存しない普遍的な行動特徴の抽出が促進され, その結果として, 同一ソースドメイン内においても行動分類の精度が向上したと考えられる. また, RGB Only と比較して Flow Only の性能が高く, 運動情報が行動識別に有効であることも確認された.

### 6.3.2 t-SNE による可視化

学習された特徴空間の構造を視覚的に分析するため, t-SNE を用いて特徴ベクトルを 2 次元空間に射影した結果を図 6.3 に示す. 図 6.3(a) は学習データとテストデータの両方を, 図 6.3(b) はテストデータのみを可視化したものである.

図 6.3(b) を参照すると, 「Running (橙色)」は特徴空間上の右側に独立したクラスを形成しており, 他の行動クラスと良好に分離されている. これは, Running が持つ大きな運動エネルギーと一貫した方向性が, 特徴空間上で支配的な差異として表現されたた






図 6.3: Animal Kingdom Dataset における特徴空間の t-SNE 可視化. (a) は全データ, (b) はテストデータのみを示す.

めである.

一方で, 中央部に位置するクラス群には, 明確な境界線が存在せず混在が見られる. この要因は, 対象クラスの性質によって以下の 2 点に大別できる.

第一に, 「Eating (緑色)」および「Sensing (紫色)」における動作レポトリの多様性である. 本実験では対象を哺乳類に限定しているが, それでも種による身体構造や生活様式の違いにより, 動作 (Motion Repertoire) は著しく異なる. 例えば, 「Eating」において, 霊長類のように前肢 (手) を使って食物を口に運ぶ動物と, 草食獣のように直接地面の草を食べる動物では, 身体の動きが全く異なる. 同様に「Sensing」においても, 後肢で立ち上がり視覚的に周囲を警戒する動作や, 地面に鼻を近づけて嗅覚を用いる動作など, 多種多様なパターンが含まれる. このように, 同一クラスラベルであっても物理的に類似しない動作が混在していることが, 特徴空間上での凝集を妨げ, 境界を不明瞭にしている主因である.

第二に, 「Walking (水色)」や「Keeping still (青色)」における環境ノイズの影響である. 本データセットには移動カメラによる映像が多く含まれており, カメラのパンやチルトによる「背景全体の動き」がオプティカルフローに混入する. この背景ノイズが, Walking のような緩慢な動作や Keeping still といった静止状態の微細な運動特徴を埋没させてしまうため, これら低運動クラス間の識別が困難になったと推察される.

また, 図 6.3(a) において, 学習データとテストデータの分布が重なり合っている点は,

表 6.5: 種識別器による分類精度の比較

| 手法                     | 評価方法                    | 種識別精度 (%)   | MCC          |
|------------------------|-------------------------|-------------|--------------|
| Gated Fusion (w/o Adv) | Fresh Probing           | 36.2        | 0.321        |
| <b>Proposed (Full)</b> | <b>Pretrained Disc.</b> | <b>10.1</b> | <b>0.036</b> |
| ランダム推測                 | -                       | 0.6         | 0.000        |

モデルが特定のサンプルに過学習することなく、ソースドメイン内での汎化性能を適切に維持していることを示している。

### 6.3.3 種識別器の分類精度

敵対的学習によって種に依存しない表現が獲得されているかを検証するため、種識別器による分類精度を評価した。本評価では、比較する手法の学習条件に応じて、以下の 2 種類の評価方法を適切に使い分けた。

- **Fresh Probing** (Gated Fusion w/o Adv で使用) :

この設定では学習時に種識別器が存在しないため、重みが固定された特徴抽出器から得られる特徴量を用いて、新規に種識別器を学習させ、その精度を評価した。これは、「特徴量そのものに動物種の情報がどの程度残留しているか」を純粋に測定するための指標である。

- **Pretrained Discriminator** (Proposed Full で使用) :

この設定では、敵対的学習のプロセスにおいて特徴抽出器と競合関係にあった「学習済みの種識別器」をそのまま用いて評価した。これは、「特徴抽出器が敵対する識別器をどの程度うまく欺くことができたか」を示す指標である。

表 6.5 に結果を示す。

敵対的学習を行わない場合 (Gated Fusion w/o Adv), 種識別精度は 36.2%, Matthews 相関係数 (MCC) は 0.321 となり、ランダム推測 (0.6%, MCC 0.0) と比較して有意に高い値を示した。これは、通常の学習では、行動認識において動物種の情報 (体型や模様など) が強力な手がかりとして利用されており、特徴ベクトルに種情報が色濃く反映されていることを意味する。

表 6.6: 各行動クラス間の特徴空間上での距離平均 (対角成分はクラス内距離)

|               | Attending | Eating       | Jumping      | Keeping still | Running      | Sensing | Walking      |
|---------------|-----------|--------------|--------------|---------------|--------------|---------|--------------|
| Attending     | 0.755     | 0.833        | 0.861        | 0.786         | 1.021        | 0.834   | 0.888        |
| Eating        | 0.833     | <b>0.672</b> | 1.020        | 0.849         | <b>1.120</b> | 0.892   | 0.903        |
| Jumping       | 0.861     | 1.020        | <b>0.648</b> | 0.831         | 0.762        | 0.872   | 0.813        |
| Keeping still | 0.786     | 0.849        | 0.831        | 0.680         | 0.942        | 0.763   | <i>0.746</i> |
| Running       | 1.021     | <b>1.120</b> | 0.762        | 0.942         | <b>0.640</b> | 0.981   | 0.804        |
| Sensing       | 0.834     | 0.892        | 0.872        | 0.763         | 0.981        | 0.722   | 0.812        |
| Walking       | 0.888     | 0.903        | 0.813        | <i>0.746</i>  | 0.804        | 0.812   | <b>0.648</b> |

一方、敵対的学習を導入した提案手法 (Proposed Full) では、精度が 10.1%, MCC が 0.036 まで大幅に低下した。MCC が 0 に極めて近いことは、識別器の予測がランダムな推測とほとんど相関がない状態まで無力化されたことを示している。この結果は、特徴抽出器が識別器を欺くことに成功し、種情報を捨象した境界不変な特徴空間が形成されたことを強く示唆している。

なお、精度が完全なランダム (0.6%) まで低下しなかった要因として、特定の行動と動物の身体構造には不可分な相関が存在するため、動きの特徴から間接的に種が推測される可能性が残ることが挙げられる。しかしながら、ベースラインと比較して識別性は著しく抑制されており、この「種情報の忘却」が、結果としてターゲットドメインへの高い汎化性能に寄与したと結論付けられる。

### 6.3.4 特徴空間におけるクラス間距離の分析

学習された特徴空間における各行動クラスの分離性を定量的に評価するため、特徴空間上でのクラス間およびクラス内におけるサンプルのユークリッド距離の平均と分散を算出した。表 6.6 に距離の平均値を、表 6.7 に距離の分散を示す。表中の対角成分は同一クラス内のサンプルペア間の距離 (クラス内距離)、非対角成分は異なるクラス間のサンプルペア間の距離 (クラス間距離) を表す。

表 6.6 の結果から、クラスの分離性について以下の傾向が読み取れる。第一に、対角成分 (クラス内距離) は、非対角成分 (クラス間距離) と比較して全体的に小さな値をとっている。特に「Running」「Jumping」「Walking」といった特徴的な運動を伴うクラスにおいては、クラス内距離が 0.640–0.648 程度と低く抑えられており、これらの行動が特徴

表 6.7: 各行動クラス間の特徴空間上での距離分散

|               | Attending | Eating | Jumping | Keeping still | Running      | Sensing | Walking      |
|---------------|-----------|--------|---------|---------------|--------------|---------|--------------|
| Attending     | 0.084     | 0.061  | 0.066   | 0.054         | 0.069        | 0.054   | 0.066        |
| Eating        | 0.061     | 0.069  | 0.077   | 0.063         | 0.086        | 0.058   | 0.100        |
| Jumping       | 0.066     | 0.077  | 0.084   | 0.059         | 0.064        | 0.054   | 0.067        |
| Keeping still | 0.054     | 0.063  | 0.059   | 0.085         | 0.103        | 0.054   | 0.079        |
| Running       | 0.069     | 0.086  | 0.064   | 0.103         | <b>0.125</b> | 0.084   | <b>0.150</b> |
| Sensing       | 0.054     | 0.058  | 0.054   | 0.054         | 0.084        | 0.080   | 0.070        |
| Walking       | 0.066     | 0.100  | 0.067   | 0.079         | <b>0.150</b> | 0.070   | 0.102        |

空間上で高い凝集性を持ってクラスタリングされていることを示している。

第二に、クラス間の距離関係に注目すると、「Eating」と「Running」の間の平均距離は 1.120 と最も大きい。これは、静的な要素を含む採食行動と、激しい動きを伴う走行行動が、特徴空間上で明確に分離されていることを意味する。対照的に、「Keeping still（静止）」と「Walking（歩行）」の間の距離は 0.746 と、異種クラス間であるにもかかわらず、クラス内距離に近い小さな値となった。これは、ゆっくりとした歩行や立ち止まりかけた状態など、両者の境界線上にある曖昧な動作が空間上で近接しており、誤分類が生じやすい構造的な要因となっていることを定量的に裏付けている。

また、表 6.7 の分散分析からは、クラス分布の形状に関する知見が得られる。特に「Running」に関連する項で分散が顕著に大きい傾向が見られた（クラス内分散：0.125, Walking とのクラス間分散：0.150）。クラス内分散の大きさは、「Running」というカテゴリ内に多様な速度や姿勢の変化が含まれ、特徴空間上で広く分布していることを示している。さらに Walking との間の分散が大きいことは、両クラスの距離が一定ではなく、サンプルによっては極めて近接していることを示唆しており、これが Running と Walking の分離を困難にする一因であると考えられる。

### 6.3.5 ゲーティングパラメータの分析

提案手法の Gated Fusion 機構が、実際にどのように外観・運動特徴を統合しているかを分析するため、学習過程におけるゲーティングパラメータ  $\alpha$  の変化を調査した。図 6.4 に、学習エポックごとの  $\alpha$  の平均値、最大値、最小値、および標準偏差の推移を示す。ここで、 $\alpha$  は運動特徴（Flow）への重みであり、値が大きいほど運動情報を重視すること




図 6.4: Gated Fusion パラメータ  $\alpha$  の学習過程における統計量の推移. (a) 平均値は約 0.2 まで低下し、多くの次元で運動特徴が抑制されていることを示す. (b) 最大値は常に 1.0 付近を維持しており、局所的には運動特徴が支配的である. (c) 最小値は 0 付近に収束している. (d) 標準偏差は約 0.2 で安定しており、次元ごとに重みが大きく異なる（選択的である）ことを示唆する.

を意味する.

分析の結果、以下の特徴が明らかになった：

1. 平均値の低下とノイズ抑制（図 6.4(a)）： $\alpha$  の平均値は学習初期の約 0.5 から急激に減少し、以降は約 0.2 付近で安定して推移している。これは、特徴次元全体の

およそ 80% の重みが外観特徴 (RGB) に割り当てられていることを意味する。前節で述べた通り、本データセットにはカメラワークによる背景の動きが多く含まれるため、モデルは学習を通じて信頼性の低い運動情報を全体的に抑制し、ノイズの影響を最小限に留める戦略を獲得したと解釈できる。

2. **決定的特徴の選択 (図 6.4(b))** : 一方で、 $\alpha$  の最大値は学習全体を通じて 1.0 に近い値を維持し続けた。平均値が低いにもかかわらず最大値が高いという事実は、特定の少数の特徴次元においては、運動特徴 (オプティカルフロー) が行動識別のための最も重要な手がかりとしてピンポイントで採用されていることを強く示唆している。
3. **特徴選択のスパース性 (図 6.4(d))** :  $\alpha$  の標準偏差は初期に減少した後、約 0.2 前後の値を維持している。平均値が 0.2 と低い状態で、標準偏差が 0.2 あるということは、パラメータの分布が 0 付近に偏りつつも、一部の高い値を持つ次元が存在するという「スパース (疎) な分布」であることを意味する。これは、Gated Fusion が全次元を均等に扱うのではなく、「不要な次元はカットし、必要な次元だけを通す」という明確な特徴選択を行っていることの統計的な証左である。
4. **考察** : 以上の挙動は、提案手法が外観情報をベースとしつつ、行動の本質に関わる重要な動き情報のみを選択的に取り入れる「適応的統合」を実現していることを示している。この機構により、背景ノイズに頑健でありながら、必要な運動情報を見落とさないロバストな特徴抽出が可能になったと結論付けられる。

## 第 7 章

# 考察

本章では，第 5 章で示した実験結果に基づき，提案手法の有効性と限界について多角的な視点から考察を行う．また，動物行動認識の実用化に向けた課題と展望についても議論する．

### 7.1 マルチモーダル統合の有効性

#### 7.1.1 外観特徴と運動特徴の相補性

実験結果より，外観特徴（RGB）と運動特徴（オプティカルフロー）は互いに相補的な役割を果たすことが確認された．ソースドメイン内（Animal Kingdom Dataset）では両者が同程度の性能を示したのに対し，ターゲットドメイン（ホッキョクグマ監視映像，アジアゾウ監視映像）では運動特徴が外観特徴を大きく上回る性能を達成した．

この結果は，行動認識における各モダリティの役割がドメインシフトの程度によって変化することを示唆している．学習データと評価データが同一分布に属する場合，外観特徴は動物の姿勢や周囲の文脈情報を効果的に捉え，行動識別に寄与する．一方，ドメインシフトが大きい場合，外観特徴は背景や照明条件の違いに過度に敏感となり，行動の本質的な情報よりも環境依存的な情報を捉えてしまう傾向がある．

運動特徴は，被写体の色や模様といった外観情報に依存せず，純粋な動きのパターンを符号化できるため，ドメイン間の環境差に対して頑健である．この特性は，動物種や撮影環境が多様な実世界応用において極めて重要であり，本研究の動機付けの妥当性を裏付けている．

### 7.1.2 Gated Fusion の適応的統合能力

提案した Gated Fusion 機構は、入力サンプルに応じて両モダリティの寄与度を動的に調整する能力を持つ。この機構により、動的な行動（走る、泳ぐなど）では運動特徴を重視し、静的な行動（立つ、座るなど）では外観特徴を重視するといった、柔軟な特徴統合が可能となる。

実験では、Gated Fusion を用いた手法が単純な連結や固定重み付けによる統合と比較して一貫して高い性能を示すことが確認された。特に、ターゲットドメインにおいて RGB Only (ARI: 0.093) と Flow Only (ARI: 0.557) の性能差が大きい中で、Gated Fusion (ARI: 0.615) が両者を効果的に統合できた点は、適応的統合機構の有効性を示す重要な証拠である。

## 7.2 種に依存しない表現の獲得

### 7.2.1 敵対的学習によるドメイン不変性

本研究では、動物種をドメインとみなし、敵対的学習により種に依存しない行動表現の獲得を試みた。実験結果より、敵対的学習の導入によりターゲットドメインにおける性能が大幅に向上 ( $\Delta \text{ARI}: +0.127$ ) したことは、この戦略の有効性を実証している。

ここで特筆すべきは、ソースドメイン (Animal Kingdom Dataset) にはホッキョクグマの映像が含まれているものの、それらは主に自然環境下で撮影されたドキュメンタリー映像であり、本実験のターゲットである「人工的な飼育環境 (檻・コンクリート)」や「固定監視カメラ特有の視点・画質」とはドメインが大きく異なる点である。また、ターゲットドメインに含まれる「常同行動」は、ソースドメインには存在しない未知の行動クラスである。

それにもかかわらず、提案手法が高い性能を発揮した事実は、獲得された特徴表現が、撮影環境や背景の差異に頑健であり、かつ学習に含まれない未知の異常行動に対しても適応可能であることを示している。この設定は、導入先の環境や発生する異常行動を事前に網羅できない実世界の監視シナリオにおいて、極めて高い実用性を有する。



### 7.2.2 種不変性と行動識別性のトレードオフ

敵対的学習の導入において懸念される課題は、種情報の除去と行動識別能力のトレードオフである。種情報を過度に抑制すれば、行動識別に有用な身体的特徴まで失われ、認識性能が低下するリスクがある。

本研究では、トリプレット損失によるクラス内分散の最小化（識別性の維持）と、敵対的損失によるドメイン不変性の獲得（種情報の抑制）を同時に最適化することで、この課題に対処した。ハイパーパラメータ  $\lambda_{grl}$  の調整には Optuna を用いることで、両目的関数の均衡点を探索した。

その結果、ソースドメイン（Animal Kingdom Dataset）における性能は低下するどころか、敵対的学習なしのモデルと比較して向上（ $\Delta ARI$ : +0.025）を示した。この事実は、種情報の抑制が行動識別能力を損なうものではなく、むしろ種固有の過学習を防ぐ「正則化」として機能し、より本質的で汎用性の高い行動特徴の抽出を促進したことを示唆している。

## 7.3 動物園実環境への適用可能性

### 7.3.1 常同行動検出による動物福祉への貢献

実験結果より、提案手法は「常同行動」を他の行動クラスから明確に分離可能であることが確認された。常同行動の有無や頻度は動物福祉の客観的な指標であり、その自動検出は、動物園における飼育管理の効率化および環境エンリッチメントの効果測定に大きく寄与する。

特筆すべきは、常同行動と通常の歩行という、運動パターンが酷似したクラス間においても良好な分離性能を示した点である。これは、敵対的学習によって動物種や背景に依存するバイアスが除去された結果、常同行動特有の「一定区間の反復」や「折り返しを含む軌跡」といった時系列的な運動構造が、より純粋に特徴量として抽出されたためと推察される。

今後は、本手法で得られた特徴空間を利用し、クラスタリングベースの教師なし異常検知と組み合わせることで、個体ごとの正常行動からの逸脱や、刻々と変化する精神状態の予兆を自動的に検出するシステムへの拡張が期待される。

### 7.3.2 ロバストな24時間連続モニタリングの実現

本研究で用いたホッキョクグマ監視映像は、動物園の固定カメラで撮影された、低解像度かつ低フレームレートの実環境データである。提案手法がこのような悪条件下でも有効に機能した事実は、専用の機材を要さず、既存の監視カメラ設備をそのまま活用できるという点で、実運用における極めて高い適用可能性を示唆している。

現在の動物園では、飼育員による定時観察が主であるが、夜間や人手が不足する時間帯における継続的なモニタリングは困難である。提案手法は外観の変化に頑健であるため、照明条件が変化する環境下でも安定した認識が期待できる。本モデルをエッジデバイス等に実装し、24時間リアルタイムに行動を定量化するシステムを構築することで、夜間の異常行動の早期発見や、季節ごとの行動パターンの長期的な変化追跡が可能となり、データ駆動型の飼育管理の実現に貢献できる。

### 7.3.3 異種動物への汎化と課題分析

本研究では、ホッキョクグマに加えてアジアゾウの監視映像に対しても評価を行い、提案手法の汎化性能を検証した。その結果、提案手法はベースラインと比較して最も高い性能を達成したものの、絶対的な精度においてはホッキョクグマと比較して低下が見られた。この性能差の主要な要因として、対象動物の特性に起因する以下の2点が挙げられる。

■**局所的運動と大域的行動の乖離** ゾウはホッキョクグマと比較して巨体であり、移動動作が緩慢である一方、長い鼻や耳は頻繁かつ複雑に動作する特性を持つ。オプティカルフローを用いた運動特徴抽出において、この「鼻の動き」が支配的な信号となり、「歩行」や「採食」といった全身の行動カテゴリを表す特徴を覆い隠すノイズとして作用した可能性がある。すなわち、局所的な部位の動きと、個体全体の行動意図との間に乖離が生じやすいことが、誤分類の一因であると考えられる。

■**行動カテゴリの連続性と境界曖昧性** ゾウの行動遷移は、ホッキョクグマと比較してより連続的である。例えば、「立っている」状態から「極めてゆっくりとした歩行」への遷移には明確な物理的境界が存在せず、人間のアノテーターにとっても区別が困難な曖昧な区間が含まれる。このような行動定義自体の曖昧さが、離散的なラベルを前提とするクラ

スタリングタスクの難易度を本質的に高めていると考えられる。

以上の考察より、提案手法の枠組みは他の動物種にも適用可能であるが、対象動物の身体構造や動作特性に応じた適応的な特徴抽出が必要であることが示唆された。具体的には、全身運動と局所運動を区別する「空間的アテンション機構」の導入や、曖昧な行動境界を許容する「ソフトクラスタリング」あるいは「階層的行動分類」のアプローチが、今後の精度向上における重要な鍵となろう。

また、Animal Kingdom Dataset [7] に含まれる広範な動物種を活用することで、より汎用的な基盤モデルの構築も期待されるが、その際は動物群（四足歩行、霊長類、鳥類など）ごとの行動様式の差異を考慮したドメイン定義や転移学習戦略の検討が不可欠である。

## 7.4 限界と今後の課題

本研究は、ドメイン汎化とマルチモーダル統合を用いた動物行動認識において一定の成果を挙げたが、実環境での完全な自動化に向けては、依然としていくつかの技術的課題が残されている。以下に、主な限界と今後の展望を述べる。

■**基盤モデルとセグメンテーションの統合によるロバスト化** 本研究では、特徴抽出器として VideoMAE を採用し、マスク映像モデリングによって背景テクスチャへの依存を抑制し、対象の構造的な動きに焦点を当てた特徴表現の獲得を図った。しかし、実験3（ソースドメイン内評価）やアジアゾウの分析で明らかになったように、水面の波紋や植生の揺れといった「動的な背景要素」がオプティカルフローや特徴量に混入し、特に行動の手がかりが微細な低運動クラスにおいて認識性能を低下させる課題が残った。

これは、VideoMAE が映像全体をトークン化して学習する際、背景領域の動きも「映像の文脈」として取り込んでしまう性質に起因すると考えられる。この限界を突破するための今後の課題として、Segment Anything Model (SAM) [23] のような強力なゼロショットセグメンテーション能力を持つ基盤モデルを VideoMAE のパイプラインに統合するアプローチが有効である。具体的には、前処理段階で SAM を用いて動物領域（前景）のみをマスクし、VideoMAE が背景トークンを物理的に無視して前景の動きのみを学習・推論できる仕組みを構築することで、環境ノイズの影響を根本的に排除したロバストな行動認識が可能になると期待される。


■**カメラワークに起因するドメインシフトへの対処** 本研究におけるドメインシフトの要因として、撮影手法の違いが挙げられる。学習データはカメラのパン・チルト・ズームを含む動的な映像が主である一方、評価データ（監視カメラ映像）は固定カメラによる静的な映像である。この差異は、特にオプティカルフロー特徴において顕著であり、学習データには「カメラの動き」と「動物の動き」が混在しているのに対し、評価データには「動物の動き」のみが含まれるという分布の不一致を生じさせている。本実験でオプティカルフローが高い性能を示したのは、ターゲットドメインが固定カメラであったため、背景の動きが抑制され、結果的に S/N 比が向上した恩恵を受けた側面も否定できない。風による植生の揺れが激しい環境や、ドローン撮影のような動的カメラへの汎化を考慮する場合、背景の動きを推定して相殺するスタビライゼーション技術や、カメラの動きと動物の自発的な動きを特徴空間上で分離する技術の導入が必要となる。

■**Animal Kingdom データセットにおける困難事例** ソースドメインとして用いた Animal Kingdom データセットは大規模である反面、行動認識が極めて困難な低品質なサンプルも少なからず含まれており、これらが学習の阻害要因となった可能性がある。主な困難事例として、以下のケースが挙げられる（図 7.1 参照）。

- **激しいカメラブレ**: 手持ちカメラでの撮影等により画面全体が激しく揺れ、オプティカルフローが動物の動きを捉えきれない事例（図 7.1(a)）。
- **重度の遮蔽（オクルージョン）**: 草むらや障害物に動物が隠れており、体の一部しか視認できない事例（図 7.1(b)）。
- **被写体の微小性**: ズームアウトや広角撮影により動物領域が極小となり、テクスチャ情報が欠落している事例（図 7.1(c)）。
- **撮影環境の悪条件**: 夜間撮影による照度不足や、スローモーション映像による運動情報の変質など、特徴抽出が困難な事例（図 7.1(d, e)）。

これらのサンプルは、実環境の多様性を反映している一方で、モデルが背景の揺れやノイズを行動特徴として誤学習する原因となり得る。図 7.1 に、これらの困難な動画のフレーム例を示す。

これらの低品質なサンプルは、モデルが誤った特徴（背景の揺れなど）を行動と関連付けて学習する原因となり得る。しかしながら、こうした「行動認識に適さない動画」を厳格にフィルタリングして除外すると、学習に使用できるデータ数が大幅に減少し、深層学習モデルの訓練に必要な規模を維持できなくなるというジレンマがある。実際、本研究の



(a) 激しいカメラブレ (Severe Camera Shake): 画面全体の揺れにより動物の固有運動が埋没している。




(b) 重度の遮蔽 (Severe Occlusion): 植生により身体の一部が隠れ、視覚情報が欠損している。



(c) 被写体の縮小 (Zoom Out & Small Object): ズームアウトにより動物の領域が極小化している。



(d) 低照度環境 (Low Illumination): 暗闇によりテクスチャや形状の判別が困難である。



(e) スローモーション (Slow Motion): 動きの変化量が極端に小さく、運動特徴が捉えにくい。

図 7.1: Animal Kingdom データセットに含まれる認識困難な動画サンプルの例。一般的な行動認識データセットと比較して、撮影条件（ブレ、遮蔽、スケール、照度、速度）の変動が極めて大きく、これが学習のノイズとなっている。

前処理段階（第4章参照）においても、クリップ長や単一条件などの最低限のフィルタリングを行っただけで、元のデータセットから多数の動画が除外された。したがって、本分野のさらなる発展のためには、ノイズの多いサンプルに対してもロバストに学習できる手法の開発に加え、動物行動分類に特化した、より高品質かつ精細な大規模動画データセットの構築が不可欠であると言える。既存のデータセットは Web 上の動画を収集したものが多く、行動解析を主目的として撮影されていないため、今後は研究目的に合致した撮影基準（固定カメラ、高解像度、遮蔽なし等）を満たす標準データセットの整備が強く望まれる。

**■時間情報集約の高度化と周期性解析** 本研究の提案手法は、常同行動を含む多様な動作を高精度に分類できており、クリップ単位での行動認識においては十分な成果を上げている。より詳細な行動解析に向けては、集約手法の改善が考えられる。現在用いている Average Pooling は、全体的な傾向を捉えるため、持続的な行動に対してはロバストであるが、一瞬の決定的な動きが平滑化されてしまう側面がある。これに対し、Max Pooling を用いれば、クリップ内で最も特徴的な瞬間を強調できる可能性があるが、ノイズの影響を受けやすくなるリスクもあるため、一概に優れているとは言えない。したがって、対象とする行動の特性に応じて手法を選択することや、Attention Pooling や NetVLAD などの学習可能な集約層を導入し、行動クラスの識別に真に重要なフレームを適応的に重み付けして選択することが有効と考えられる。

さらに、常同行動の本質である「反復性」や「持続性」を捉えるためには、単純な集約だけでなく、長期間の周期性解析が不可欠である。現在の数秒単位の特徴抽出に加え、数分から数十分のスケールで特徴量の時系列変化に対して自己相関やフーリエ変換を適用することで、ペーシングなどのリズムを定量化できる。また、TimeSformer [24] や ViViT [25] などの Video Transformer アーキテクチャを導入し、Self-Attention 機構によって長距離の時間的依存関係を学習することで、局所的な動作（歩行）と大域的なパターン（反復）を階層的に統合した理解が可能になると期待される。

**■実運用における行動境界の曖昧性と連続性** 本研究では、30 秒の動画クリップに対して Sliding Window と Average Pooling を適用し、特徴を集約して分類を行っている。しかし、実際の動物園環境における行動は連続的であり、固定長のウィンドウ内において「歩行」から「静止」、あるいは「採食」へと行動が遷移する状況が頻発する。現状の単純な平均化集約では、ウィンドウ内で支配的な動作に分類結果が引きずられたり、複数の行動特徴が混在することで境界付近の識別精度が低下する懸念がある。

この課題に対しては、フレーム単位で行動クラスを予測する時間的アクションセグメンテーション技術の導入や、オンラインで行動の切り替わりを即座に検出する変化点検知を組み合わせることで、より細粒度かつ時間分解能の高い行動認識が可能になると考えられる。

## 第 8 章

# 結論

### 8.1 本研究のまとめ

本研究では、動物種および撮影環境の多様性に頑健な動物行動認識の実現を目指し、マルチモーダル表現学習と敵対的学習を組み合わせた、ドメイン汎化に基づく新しい行動認識手法を提案した。

提案手法は、RGB 映像から抽出される外観特徴と、オプティカルフローから抽出される運動特徴を Gated Fusion 機構により適応的に統合する。さらに、動物種をドメインとみなした敵対的学習を導入することで、種固有の身体的特徴や背景バイアスに依存しない、汎用的な行動特徴表現の獲得を実現した。

本研究によって得られた主な成果は以下の通りである：

1. **マルチモーダル表現学習の有効性の実証**：Gated Fusion を用いることで、入力映像の特性に応じて外観と運動の重要度を動的に調整し、単一モダリティの限界を補完できることを実証した。特に、ドメインシフトの大きいターゲット環境においては、背景不変性の高い運動特徴が支配的な役割を果たし、認識精度の維持に大きく貢献することを明らかにした。
2. **敵対的学習による種不変表現の獲得**：種分類器との敵対的学習を通じて、種情報と環境バイアスを抑制することで、学習データ（自然環境下のドキュメンタリー映像）とはドメインが大きく異なる未知の飼育環境に対しても有効な不変表現が獲得可能であることを示した。学習データにはホッキョクグマが含まれているものの、撮影条件や背景が劇的に変化するターゲット環境において性能を維持できた点は、



本手法の高い環境ロバスト性を裏付けている。

3. **実環境データでの有効性の検証**：動物園の固定監視カメラで撮影された、低解像度かつ低フレームレートの実映像を用いた評価実験により、提案手法の実運用への適用可能性を実証した。特に、学習データには含まれない未知の行動クラスである「常同行動」を、類似する通常の歩行動作から明確に分離・検出できたことは、動物福祉に貢献する実用面での大きな成果である。

定量的評価において、提案手法はホッキョクグマ監視映像に対して ARI 0.742, NMI 0.728 を達成し、敵対的学習を用いない手法 (ARI 0.615) と比較して 0.127 ポイントの性能向上を実現した。この結果は、動物種をドメインとして扱う敵対的学習がドメイン汎化に有効であることを示している。

結論として、本研究で提案したフレームワークは、学習データの不足や環境の多様性という課題を抱える動物行動認識分野において、汎用性と実用性を兼ね備えた一つの解を提示したと言える。今後、第 7 章で議論した課題に取り組み、本手法をさらに発展させることで、動物園や野生環境における動物福祉の向上および保全活動に貢献する、自律的かつ持続可能なモニタリングシステムの実現が期待される。

# 謝辭

## 参考文献

- [1] David J. Mellor. Updating animal welfare thinking: Moving beyond the five freedoms towards a life worth living. *Animals*, Vol. 6, No. 3, p. 21, 2016.
- [2] Donald M. Broom. Indicators of poor welfare. *British Veterinary Journal*, Vol. 142, No. 6, pp. 524–526, 1986.
- [3] Georgia J. Mason. Stereotypies: a critical review. *Animal Behaviour*, Vol. 41, No. 6, pp. 1015–1037, 1991.
- [4] João Carreira and Andrew Zisserman. Quo vadis, action recognition? a new model and the kinetics dataset. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 6299–6308, 2017.
- [5] Karen Simonyan and Andrew Zisserman. Two-stream convolutional networks for action recognition in videos. In *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 568–576, 2014.
- [6] Yaroslav Ganin, et al. Domain-adversarial training of neural networks. *Journal of Machine Learning Research*, Vol. 17, No. 59, pp. 1–35, 2016.
- [7] Xun Long Ng, Kian Eng Ong, Qichen Zheng, Yun Ni, Si Yong Yeo, and Jun Liu. Animal kingdom: A large and diverse dataset for animal behavior understanding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 19023–19034, 2022.
- [8] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xi-aohua Zhai, et al. An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*, 2020.
- [9] Alexander Mathis, Pranav Mamidanna, Kevin M. Cury, Taiga Abe, Venkatesh N. Murthy, Mackenzie Weygandt Mathis, and Matthias Bethge. Deeplabcut: mark-

- erless pose estimation of user-defined body parts with deep learning. *Nature Neuroscience*, Vol. 21, No. 9, pp. 1281–1289, 2018.
- [10] Jun Chen, Tan-Kee Ng, and Stefan Scherer. Mammalnet: A large-scale video benchmark for mammal recognition and behavior understanding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- [11] Maksim Kholiavchenko, Jadie Kline, Steven Ramirez, Lindsey Brodie, Nikhil Shah, and Tanya Berger-Wolf. Kabr: In-situ dataset for kenyan animal behavior recognition from drone videos. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pp. 31–40, 2024.
- [12] Yuji Wang, Hiroki Tanaka, and Yuki Sato. Automated detection of stereotypic behavior in zoo animals using surveillance cameras. *Applied Animal Behaviour Science*, Vol. 258, p. 105812, 2023.
- [13] Yoshua Bengio, Aaron Courville, and Pascal Vincent. Representation learning: A review and new perspectives. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 35, No. 8, pp. 1798–1828, 2013.
- [14] Florian Schroff, Dmitry Kalenichenko, and James Philbin. Facenet: A unified embedding for face recognition and clustering. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 815–823, 2015.
- [15] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, et al. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, pp. 8748–8763, 2021.
- [16] Eric Tzeng, Judy Hoffman, Kate Saenko, and Trevor Darrell. Adversarial discriminative domain adaptation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 7167–7176, 2017.
- [17] Zhan Tong, Yibing Song, Jue Wang, and Limin Wang. Videomae: Masked autoencoders are data-efficient learners for self-supervised video pre-training. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [18] Zachary Teed and Jia Deng. Raft: Recurrent all-pairs field transforms for optical flow. In *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 402–419, 2020.

- [19] Christoph Feichtenhofer. X3d: Expanding architectures for efficient video recognition. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 203–213, 2020.
- [20] Yirong Wang, Xiatian Zhu, and Shaogang Gong. Multi-similarity loss with general pair weighting for deep metric learning. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 5022–5030, 2019.
- [21] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta, and Masanori Koyama. Optuna: A next-generation hyperparameter optimization framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pp. 2623–2631, 2019.
- [22] Laurens van der Maaten and Geoffrey Hinton. Visualizing data using t-sne. *Journal of Machine Learning Research*, Vol. 9, pp. 2579–2605, 2008.
- [23] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C Berg, Wan-Yen Lo, et al. Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 4015–4026, 2023.
- [24] Gedas Bertasius, Heng Wang, and Lorenzo Torresani. Is space-time attention all you need for video understanding? In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, pp. 813–824, 2021.
- [25] Anurag Arnab, Mostafa Dehghani, Georg Heigold, Chen Sun, Mario Lucic, and Cordelia Schmid. Vivit: A video vision transformer. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 6836–6846, 2021.